Transcrição da simulação Entender e limpar os dados

1. Você transferiu por upload os dados do seu arquivo CSV para o seu projeto e esta é uma visualização. Você pode começar a explorar o seu conjunto de dados aqui na visualização ou pode começar a utilizar a ferramenta de refinamento de dados. Vamos começar. Selecione **Preparar dados** para começar o refinamento de dados.
2. Pode levar alguns minutos para a ferramenta de refinamento de dados ler e refinar os dados. Antes, o conjunto de dados era somente leitura, mas agora ele é editável, permitindo que você possa trabalhar com ele. Observe que há três guias na parte superior: **Dados**, **Perfil** e **Visualizações**. Selecione a seta **Avançar** para continuar.

   Agora você está pronto para entender e limpar os dados

   Lembre-se, estes dados são de reivindicações de seguro de automóveis que a empresa aprovou. O objetivo do seu projeto é prever reivindicações fraudulentas. Portanto, deve-se examinar a **previsibilidade** dos dados em **cada coluna**. Os dados na coluna irão ajudar você a prever fraudes? Algumas colunas irão e outras não. Cabe a você decidir. Vamos ver.

   Selecione **X** para fechar esta janela e continuar.

3. As primeiras quatro colunas contêm números de identificação, tais como o ID do motorista e o ID da apólice. Estes dados não ajudam a prever quem poderá cometer fraude. Eles são apenas identificadores. Vamos ter certeza. Selecione a guia **Perfil**.
4. A **guia** Perfil na ferramenta de refinamento de dados oferece estatísticas descritivas que a ferramenta calculou a partir dos dados. Ela o ajuda a analisar e a decidir o que deve ser mantido e removido. Selecione a seta **Avançar** para continuar.
5. Ao analisar as estatísticas das primeiras quatro colunas, foram encontradas 975 ocorrências exclusivas. Se você vir estatísticas que apenas contam as linhas em um arquivo CSV, então é necessário remover essa coluna. Não há nada de interessante nos dados e não são previsíveis. Selecione a guia **Dados**.
6. Vamos excluí-los. Selecione os **três pontinhos** ao lado da coluna **HOUSEHOLD_ID**. Isso lhe proporciona várias opções do que você pode fazer na coluna. Selecione **Remover coluna**.
7. Faça o mesmo com os outros dados identificadores que não ajudarão seu projeto a prever comportamentos fraudulentos. Selecione os **três pontinhos** ao lado da coluna **DRIVER_ID**. Selecione **Remover coluna**.
8. Selecione os **três pontinhos** ao lado da **coluna** POLICY_ID. Selecione **Remover coluna**.
9. Selecione os **três pontinhos** ao lado da **coluna** CLAIM_ID. Selecione **Remover coluna**.
10. Agora você está entendendo e limpando os dados! Você passou de 38 colunas para 34 colunas. Vamos continuar a entender e a limpar. Selecione a seta **Avançar** para continuar.
11. A **coluna** INCIDENT_CAUSE é interessante. Trata-se da causa do acidente de automóvel em que 1 é devido a erro do motorista, 2 é causado por causas naturais, 3 é por outro erro de motorista, 4 é por um crime e 5 é por outras causas. Isso poderá ajudá-lo a prever uma fraude. Selecione a guia **Perfil** para investigar mais em detalhe.
12. A ferramenta de refinamento de dados está apresentando estatísticas interessantes para o campo **INCIDENT_CAUSE**. Observe que há um valor para **Desvio Padrão**. O que isso significa? Selecione a seta **Avançar** para continuar.

    O que é desvio padrão? O desvio padrão é um cálculo estatístico que o informa o quão dispersos os dados estão em relação à média.

- A média é a média de um conjunto de dados.
- Um desvio padrão baixo significa que os dados estão agrupados em torno da média.
- Um desvio padrão elevado indica que os dados estão mais dispersos.

Para você, qualquer coluna na guia **Perfil** que tenha um valor no campo Desvio **padrão poderá** conter dados interessantes para previsões em seu projeto. Mantenha estes dados.

Selecione **X** para fechar esta janela e continuar.

13. Vamos continuar. Selecione a **guia** Dados para investigar mais colunas de dados.
14. Observe que **a** coluna DESCRIÇÃO está em branco. É possível que você se depare com dados ausentes ao trabalhar em um projeto. Não ajuda em nada. Selecione os **três pontinhos** e selecione **Remover coluna**.
15. A coluna seguinte para **CLAIM_STATUS** é interessante. Ela possui dados sobre o status da reivindicação na qual 1 significa aberta, 2 é aprovada, 3 é paga e 4 é sinalizada como possível fraude. Esta coluna pode definitivamente ajudá-lo a prever a fraude, por isso a mantenha. Selecione a seta **Avançar** para continuar.
16. Você pode manter a **coluna** ODOMETER_AT_LOSS porque ela poderá ser interessante para considerar a quilometragem do carro no momento do acidente. Selecione a seta **Avançar** para continuar.
17. Em seguida, analise as **colunas** LOSS_EVENT_TIME **e** CLAIM_INIT_TIME. Selecione a **seta Continuar** para continuar.

    Lembre-se de ser curioso!

    Para este projeto de ciência de dados, é uma prática recomendada manter aquelas colunas que tenham informações de data e hora. Nunca se sabe o que elas podem revelar em termos de previsões. Por exemplo, se alguém esperou muito tempo para protocolar uma reivindicação em vez de fazê-lo no dia do acidente de automóvel, o que isso pode significar?

    Observe como você está sendo curioso. Você é como um detetive seguindo pistas! Cientistas de dados precisam pensar assim.

    Você pode manter as **colunas** LOSS_EVENT_TIME **e** CLAIM_INIT_TIME. Selecione X **para fechar esta janela e continuar.**

18. É essencial salvar o seu trabalho enquanto você o faz. E salvar frequentemente! No canto superior direito, selecione o **ícone** Salvar.
19. Em seguida, a **coluna** POLICE_REPORT é importante e poderá ser útil. Observe que o tipo de dados é chamado de Número Inteiro. Isso significa que é um 0 (significando não) ou um 1 (significando sim). Ou foi registrado um boletim de ocorrência policial ou não foi. Você pode manter esta coluna. Selecione a **seta Avançar** para continuar.
20. Vamos avançar para a coluna **CLAIM_AMOUNT**. Quanto custou consertar o carro após o acidente? Isto é bem interessante para o seu projeto. Sua empresa paga essas reivindicações. Mantenha esta coluna. Selecione a **seta Avançar** para continuar.
21. A seguir, revise a coluna FLAG_FOR_FRAUD_INV. Selecione a seta Avançar para continuar.

    Reivindicações foram marcadas para fraudes

    A coluna **FLAG_FOR_FRAUD_INV** é exclusiva. Os dados são provenientes da equipe de investigadores de fraude que revisou e concluiu se a reivindicação da pessoa naquela linha não era fraude (0) ou era fraude (1). Eles foram inseridos posteriormente, no final do ano. Estas são

respostas conhecidas por você. Esses dados são um conjunto de treinamento para a ferramenta construir um modelo de treinamento supervisionado. O IBM Watson Studio analisará esta coluna, selecionará dados aleatoriamente e construirá padrões para você.

Você pode manter a coluna FLAG_FOR_FRAUD_INV. Lembre-se disso também mais tarde quando você visualizar os dados.

Selecione **X** para fechar esta janela e continuar.

22. Em seguida, a coluna PRIMARY_DRIVER_ID tem dados identificadores. Lembre-se de que os dados do tipo ID não serão previsíveis para este projeto. Selecione os **três pontos** e selecione **Remover coluna**.
23. É essencial salvar o seu trabalho enquanto você o faz. E salvar frequentemente! No canto superior direito, selecione o **ícone** Salvar.
24. Vamos avançar para as colunas FIRST_NAME e LAST_NAME. Esses dados podem ajuda você a prever fraudes? Selecione a seta **Avançar** para continuar.

    Seja cuidadoso com as informações pessoais (PI)

    Algumas colunas em seu conjunto de dados representam informações pessoais (PI) sobre a pessoa fictícia que fez a reivindicação automática que foi paga pela sua empresa.

    Informações pessoais são quaisquer informações relacionadas a um indivíduo vivo e identificável. Quando coletadas, as informações pessoais podem levar à identificação de uma determinada pessoa. . Por exemplo, nome e sobrenome, números de telefone, endereços de e-mail, números de placa do veículo e datas de nascimento são informações pessoais. Você deve estar ciente desses dados em projetos e se eles podem ser utilizados.

    Se você analisar este projeto de ciência de dados, verá que informações pessoais não são previsíveis para fraude. O nome ou endereço de e-mail de alguém não ajudará você a prever fraudes. Nós removeremos esses dados para você.

    Selecione **X** para fechar esta janela e continuar.

25. Até agora, você removeu colunas com dados ausentes ou não previsíveis. Há outra etapa para limpar os dados. Você deve examinar o tipo de dados de cada coluna para ter certeza de que está correto. A ferramenta de refinaria de dados já fez algumas correções. Selecione a seta **Avançar** para continuar.
26. Repare que o tipo de dados para ODOMETER_AT_LOSS é corretamente apresentado como Decimal. Selecione a **seta Avançar** para continuar.
27. Mas, o tipo de dados para **LOSS_EVENT_TIME** é Sequência de caracteres. As sequências de caracteres são uma sequência de letras, dígitos, pontuação e assim por diante como um endereço de correspondência. Esta coluna deve estar correta para ser uma Data, para que a ferramenta possa fazer cálculos. Selecione os **três pontos** e selecione **Converter tipo de coluna**.
28. A janela esquerda permite customizar o tipo de dados para a sua coluna. No menu suspenso Tipo, selecione Data.

29. Na lista Selecionar a ordem..., você verá que mdy agora está selecionado. Isto significa que os dados serão exibidos como mês (m), dia (d) e ano (y). Selecione **Aplicar**.
30. Repare a sua atualização salva e a coluna **LOSS_EVENT_TIME** que agora exibe corretamente o tipo de dados como Data. O restante dos tipos de dados serão atualizados automaticamente e,

assim, você pode avançar. Selecione a seta **Avançar** para continuar.

31. Agora você está pronto para salvar o seu trabalho e criar uma tarefa de refinaria na ferramenta. Isto cria um arquivo CSV separado que contém as suas alterações. Na barra de ferramentas superior, à direita de onde se salva, selecione **Salvar e criar uma tarefa**.
32. Para criar uma tarefa para o seu projeto, comece digitando “Prevendo fraudes em seguro de automóveis” no campo **Nome** e depois pressione **Enter**.
33. Você pode deixar o **campo** Descrição em branco. Selecione **Avançar**.
34. Na seção Configurar, você pode aceitar os padrões. Selecione **Avançar**.
35. Na seção Planejamento, você pode manter o planejamento desativado. Observe que se o trabalho neste projeto for de longo prazo, você pode querer programar a tarefa para ser executada à meia-noite, caso ela leve muito tempo, para que esteja pronta quando você começar a trabalhar. Selecione **Avançar**.
36. Na seção Notificação, você pode manter as notificações desativadas. Selecione **Avançar**.
37. Repare que o arquivo CSV original que você transferiu por upload está em Origem. Em Destino está o seu novo arquivo CSV que a ferramenta de refinamento de dados está criando para você. Ele tem "_shaped" no nome do arquivo. Este é o arquivo para acessar daqui em diante para o seu projeto. Selecione **Criar e executar**.
38. Repare na notificação! A tarefa foi criada com sucesso. Selecione a seta Avançar para continuar.

Você limpou com sucesso o conjunto de dados removendo colunas incompletas e colunas com dados que não são previsíveis. Você também corrigiu o tipo de dados apresentado para uma coluna para obter cálculos corretos e criou a tarefa na ferramenta.